KARADENİZ TEKNİK ÜNİVERSİTESİ OF TEKNOLOJİ FAKÜLTESİ

YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ

1. Giriş

Sınıflandırma, veri madenciliğinin önemli bir parçasıdır. Sınıflandırma kavramı, basitçe bir veri kümesi üzerinde tanımlı olan çeşitli sınıflar arasında veriyi dağıtmaktır. Sınıflandırma algoritmaları, verilen eğitim kümesinden bu dağılım şeklini öğrenirler ve daha sonra sınıfının belirli olmadığı test verileri geldiğinde doğru şekilde sınıflandırmaya çalışırlar. Veri kümesi üzerinde verilen bu sınıfları belirten değerlere etiket ismi verilir ve gerek eğitim gerekse test sırasında verinin sınıfının belirlenmesi için kullanılırlar.

Sınıflandırma alanında birçok yöntem ve algoritma geliştirilmiştir. Bu yöntemler arasında en yaygın kullanılan algoritmalardan bir tanesi k- en yakın komşu (k-nn) algoritmasıdır. Genel olarak k-nn, sınıflandırma sırasında çıkarılan özelliklerden, sınıflandırılmak istenen yeni bireyin daha önceki bireylerden k tanesine olan yakınlığına bakılmasıdır.

Bir diğer yöntem olan yapay sinir ağları da sıklıkla sınıflandırma problemlerinde kullanılmaktadır. Yapay sinir ağları insan beyninden esinlenerek insanda bulunan yeni bilgiler öğrenme, yeni çıkarımlar yapma gibi yetenekleri otomatik olarak gerçekleştiren bir yöntemdir ve sınıflandırma, modelleme ve tahmin gibi birçok günlük hayat probleminin çözümünde kabul edilebilir başarılar gösterebilmektedir.

K-NN algoritmasında komşulara olan uzaklık hesaplamasında bağımsız değişkenlerin etki oranının daima 1 alınması ve YSA ağırlıkların bulunması için kullanılan geleneksel algoritmalar, yerel optimum tuzaklarına takılabilmektedirler. Bu nedenle yüksek doğruluk oranı gösteremeyebilirler. YSA ve K-NN de en iyi değerlerinin bulunması bir optimizasyon problemidir. Literatürde optimizasyon alanında sıklıkla kullanılan ve özellikle karmaşık problemlerde kabul edilebilir çözümler bulabilen meta sezgisel algoritmalar ile YSA ve K-NN modellerinde ağırlıkların en uygun değerlerinin bulunmasında kullanılabilir. Bu çalışmada Sezgisel Algoritma olarak SOS (Symbiosis Organisms Search) algoritması kullanılmıştır.

1.1 Sezgisel K- En Yakın Komşuluk Algoritması

Sezgisel k-nn, k- en yakın komşu algoritması ve sezgisel arama algoritmalarının teknikleri ile hibrit bir yapı oluşturularak geliştirilmiş bir yöntemdir. K-nn algoritmasında sınıflandırma yapılırken eldeki verilerin birbirlerine olan uzaklığı veya benzerliği kullanılır. Veriler arasındaki mesafe ölçülürken kullanılan yöntemler Öklid, Manhattan ve Minkovski uzaklık metriklerinden biri olabilir. Klasik K-nn algoritmasında uzaklık hesaplaması yapılırken kullanılan niteliklerin her biri çıktılar üzerinde aynı etkiye sahiptir. Ancak bu çıktılar üzerinde etkisi aynı olan niteliklerin ayrı bir ağırlığı olabilir. Niteliklerin farklı etkilerinin olması durumunda çözüm olarak bu niteliklere etkilerine göre bir ağırlık değeri atanır. Doğru ağırlıkların bulunması ise bir optimizasyon problemidir dolayısıyla bu noktada devreye meta-sezgisel arama algoritmaları girmektedir. Sezgisel algoritma bu niteliklerin ağırlık değerleri için optimum değerleri bulacak olan yöntemdir. Optimizasyon bakış açısıyla k-en yakın algoritmasındaki ilgili uzaklık metriği amaç fonksiyonuna tekabül etmektedir. Uzaklık hesabı yapılarak k-nn algoritmasından geriye dönecek hata değeri minimize edilecek değerdir. Çözüm adaylarının boyutu tasarım değişkenlerinin sayısı kadar olurken, çözüm adaylarındaki her bir parametre etki oranı yani ağırlık değeridir. Arama uzayındaki ağırlık değerleri 0-1 arasındadır. 1 etki oranı %100 iken 0'da etki oranı %0dır.

Aşağıda klasik k-en yakın komşu algoritmasının ve sezgisel k-en yakın komşu algoritmasının uzaklık hesabına ait denklemler verilmektedir. Klasik K-nn algoritmasında uzaklık hesaplaması yapılırken kullanılan niteliklerin her biri çıktılar üzerinde aynı etkiye sahiptir. Klasik k- en yakın komşu algoritmasına ait denklemler:

Öklid Uzaklığı : $d(q_x, q_y) = \sqrt{\sum_{i=1}^{n}(Fq_{x[i]} - Fq_{y[i]})^2}$ (1)

Manhattan Uzaklığı : $d(q_x, q_y) = \sum_{i=1}^{n}(|Fq_{x[i]} - Fq_{y[i]}|)$ (2)

Çıktılar üzerinde farklı etkisi olan niteliklere ayrı bir etki oranı/ağırlık verildiğinde Sezgisel k-en yakın komşu algoritmasına ait uzaklık metrikleri:

Öklid Uzaklığı : $d(q_x, q_y) = \sqrt{\sum_{i=1}^{n} W_{FT[\dot{\mathrm{i}}]} * (Fq_{x[i]} - Fq_{y[i]})^2}$ (3)

Manhattan Uzaklığı : $d(q_x, q_y) = \sum_{i=1}^{n} W_{FT[\dot{\mathrm{i}}]} * (|Fq_{x[i]} - Fq_{y[i]}|)$ (4)

Bulunan optimum değerlerin ağırlık matrisi:

$$W_{FT[m]} = \begin{bmatrix} W_{FT[0,0]} & \cdots & W_{FT[0,m-1]} \\ \vdots & \ddots & \vdots \\ W_{FT[n-1,0]} & \cdots & W_{FT[n-1,m-1]} \end{bmatrix} \quad (5)$$

Yapılan çalışmada KNN için Öklid ve Manhattan uzaklık formülleri kullanılmıştır. Oylama yöntemleri olarak klasik ve ağırlıklı oylama kullanılmıştır. En uygun komşu sayısının belirlenmesinde 1'den 30'a kadar ilgili veri setinde sınıflandırma yapılarak hata oranı en düşük komşu belirlenmiştir.

1.2 Sezgisel Yapay Sinir Ağı

Sezgisel YSA, yapay sinir ağları ve sezgisel arama algoritmalarının teknikleri ile hibrit bir yapı oluşturularak geliştirilmiş bir yöntemdir. Yapay sinir ağlarında eğitim, ilgili YSA'nın nöronları arasındaki ağırlıkların değiştirilmesiyle gerçekleştirilmektedir. Bu ağırlık değerleri değiştikçe bilgilerin ağ içerisindeki dağılımları, dolayısıyla çıktı değerleri değişmektedir. Ağırlıkların sürekli yenilenip istenilen sonuca ulaşana kadar geçen zamana öğrenme denir. Eğitim sürecinin ne zaman sonlandırılacağına karar vermek ezberleme probleminin önüne geçmek ve en etkili modeli yaratmak için önemlidir. Ağın eğitimini sonlandırmaya karar vermek için doğrulama veri

setindeki hata değişimi dikkate alınır. Ağırlıkların hatayı en küçükleyecek şekilde değiştirilmesiyle sınıflandırma işlemini gerçekleştirmektedir. Meta-sezgisel algoritmalarda popülasyondaki her bir dizi, YSA ağırlıklarını ifade etmektedir. Ağırlık değerleri matrisler aracılığıyla tutulmaktadır ve matris boyutları Tablo 1'de verilmiştir.

Tablo 1. YSA eğitimi için tutulan ağırlık matrisleri

Katmanlar	**Boyut**
Girdi katmanı ile gizli katman arası	Girdi sayısı × gizli katmandaki nöron sayısı
Gizli katman ile çıktı katmanı arası	Gizli katmandaki nöron sayısı × çıktı sayısı
Gizli katman eşik değerleri	Gizli katman nöron sayısı
Çıktı katmanı eşik değerleri	Çıktı sayısı

Şekil 1'de 3 girdi 2 çıktılı bir problem için gizli katmanında 4 nöron içeren YSA yapısında ağırlık matrisleri gösterilmektedir. Şekilden de görüldüğü gibi girdi-gizli katman ağırlıklarının tutulduğu matris 3×4 boyutunda, gizli-çıktı ağırlıklarının tutulduğu matris 4×2 boyutunda, gizli katman eşik ağırlıklarının tutulduğu matris 6×1 boyutunda ve çıktı eşik ağırlıklarının tutulduğu matris 2×1 boyutundadır.

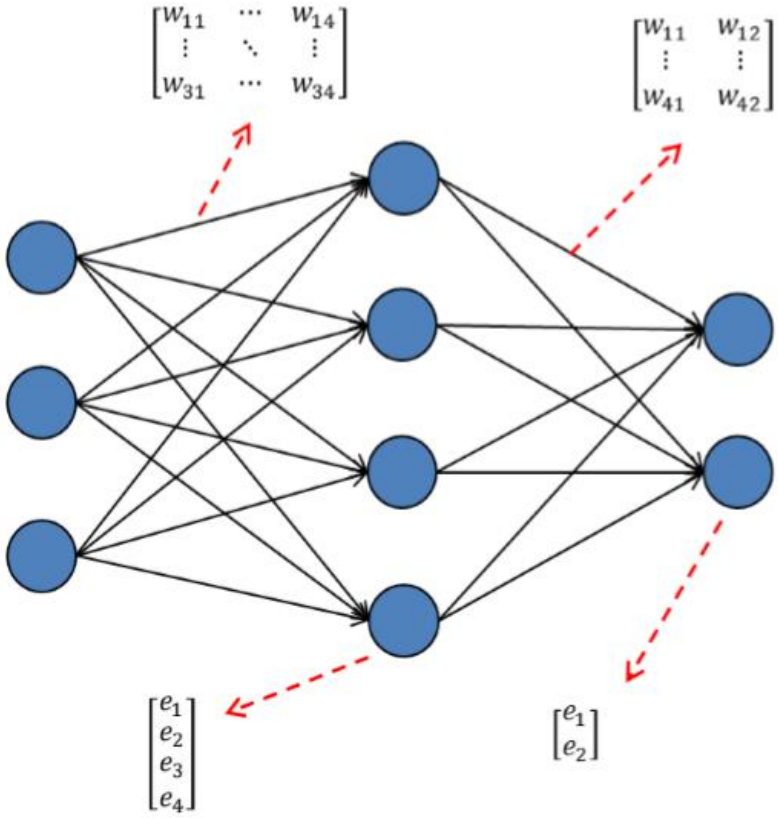

Şekil 1. YSA eğitimi için tutulan ağırlık değerleri matrisleri

KULLANILAN AKTİVASYON FONKSİYONLARI

Yapılan çalışmada YSA için Sigmoid, Hiperbolik, Sinüs, Esik Değer, Relu ve Leaky Relu aktivasyon fonksiyonları kullanılmıştır. Sinir hücrelerinin birleştirme fonksiyonlarında ise Toplam, Çarpım, Min ve Max fonksiyonları kullanılmıştır. Sinir hücrelerinin ağırlıklarının yanında en uygun birleştirme ve aktivasyonlarının belirlenmesinde sezgisel algoritma kullanılmıştır.

Yapay sinir ağlarında sinir düğümlerinin çıktısını almakta kullanılan fonksiyona aktivasyon fonksiyonu denir. Transfer fonksiyonu olarak da bilinir. Yapay sinir ağlarına doğrusal olmayan gerçek dünya özelliklerini tanıtmak için aktivasyon fonksiyonuna ihtiyaç duyulur. Yapay sinir ağında x girdiler, w ağırlıklar ve ağın çıkışına aktarılan değere f(x) yani aktivasyon işlemi uygulanır. Aktivasyon fonksiyonu kullanılmayan bir sinir ağı sınırlı öğrenme gücüne sahip bir doğrusal bağlanım (linear regression) gibi davranacaktır. Sinir ağımıza öğrenmesi için görüntü, video, yazı ve ses gibi karmaşık gerçek dünya bilgileri verileceğinden doğrusal olmayan aktivasyon fonksiyonlarına ihtiyaç vardır ve bu sayede ağların daha güçlü öğrenmesi sağlanabilir. Ağırlıklar ile ilgili hata değerlerini hesaplamak için yapay sinir ağında hatanın geriye yayılımı algoritması uygulanmaktadır.

Sigmoid Fonksiyonu

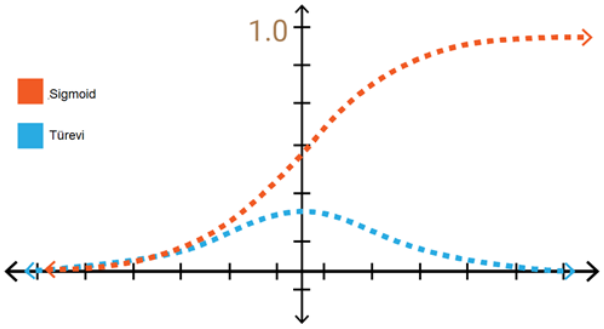

Sigmoid aktivasyon fonksiyonu sürekli ve türevi alınabilir bir fonksiyondur Doğrusal olmayışı dolayısıyla yapay sinir ağları uygulamalarında en sık kullanılan fonksiyondur. Bu fonksiyon girdi değerlerinin her biri için 0 ile 1 arasında bir değer üretir. Katmanları sıralanabilir, basamak fonksiyonundan farklı olduğu için türevlenebilirdir. Yavaş bir öğrenme olayı gerçekleştiğinde hatayı minimize eden optimizasyon algoritması yerel (lokal) minimum değerlere takılabilir ve yapay sinir ağı modelinden alınabilecek maksimum performans alınamaz.

Formül :

$$F(Net) = \frac{1}{1+ e^{-Net}} \tag{6}$$

Hiperbolik Tanjant Fonksiyonu

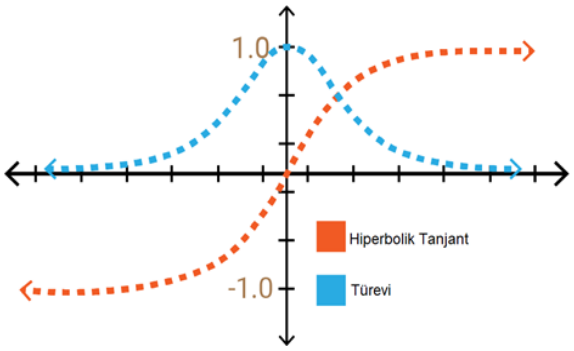

Sigmoid fonksiyonuna çok benzer bir fonksiyondur. Ancak hiperbolik tanjant fonksiyonunun çıkış değerleri -1 ile 1 arasında değişir. Türevinin daha dik olması yani daha çok değer alması sigmoid fonksiyonuna göre avantajdır. Bu da daha hızlı öğrenme ve sınıflama işlemi için daha geniş aralığa sahip olmasından dolayı daha verimli olacağı anlamına gelir. fonksiyonun uçlarında gradyanların ölmesi problemi sebebiyle maksimum performans alınamaz.

Formül :

$$F(Net) = \frac{e^{Net} + e^{-Net}}{e^{Net} - e^{-Net}} \tag{7}$$

Sinüs Fonksiyonu

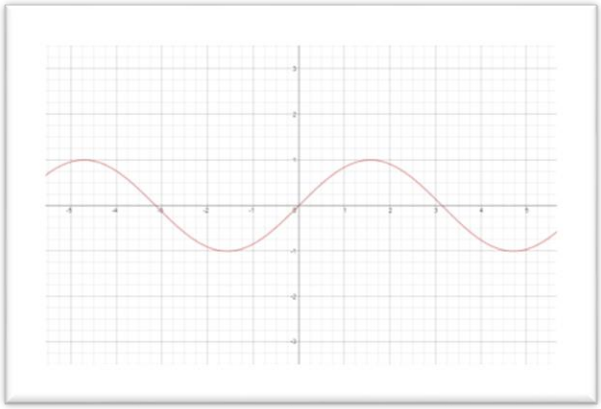

Öğrenilmesi düşünülen olayların sinüs fonksiyonuna uygun değer gösterdiği durumlarda kullanılır.

Formül :

$$F(Net) = \sin(Net) \tag{8}$$

Eşik Değer Fonksiyonu

Gelen bilgiler sıfırdan küçük eşit olduğunda 0 çıktısı, 1’ den büyük eşit olduğunda 1 çıktısı, 0 ile 1 arasında olduğunda ise yine kendisini veren çıktılar üretebilir.

Formül :

$$F(Net) = \begin{cases} 0, & if\ Net \leq 0 \\ Net, & if\ \ 0 < Net < 1 \\ 1, & if\ Net \geq 1 \end{cases} \quad (9)$$

ReLU (Rectified Linear Unit) Fonksiyonu

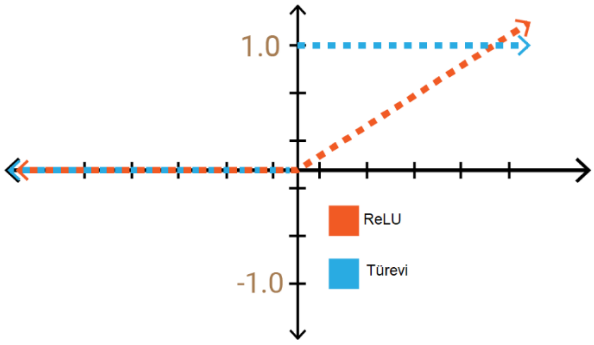

Doğrusal olmayan bir fonksiyondur**.** İyi bir tahmin edicidir. ReLU'nun kombinasyonları ile herhangi başka bir fonksiyona da yakınsamak mümkündür. ReLU fonksiyonunun hem kendisi hem de türevi monoton fonksiyondur. Herhangi bir negatif değer ReLU tarafından sıfır olarak döndürülür. Negatif eksende 0 değerlerini alması ağın daha hızlı çalışacağı anlamına gelirken tüm negatif değerlerin 0'a çevrilmesi modelin uygun bir şekilde eğitilmesini engeller. Bu nedenle model negatif değerler ile eğitilemez.

Formül :

$$F(Net) = \max(0, x) \quad (10)$$

Sızıntı (Leaky) ReLU Fonksiyonu

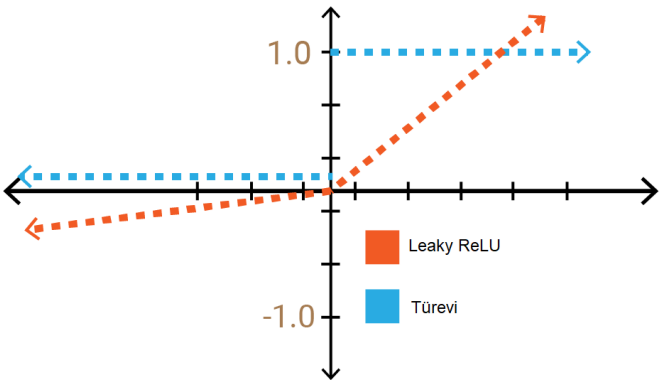

Leaky ReLU negatif değerlerin ReLU'da yok olmasını engellemek için geliştirilmiştir. Bu aktivasyon fonksiyonunda, ReLU'dan farklı olarak, negatif değerler için aktivasyon fonksiyonuna eğim eklenilmesini sağlayan bir değer seçilir. Seçilecek bu değer, sabit küçük (0.001) bir değer olursa aktivasyon fonksiyonu Leaky-ReLU şeklinde isimlendirilir.

Formül :

$$F(Net) = \max(0.01x, x) \tag{11}$$

Birleştirme(Toplama) Fonksiyonu

Toplama fonksiyonu bir yapay sinir hücresine ağırlıklarla çarpılarak gelen girdileri toplayarak o hücrenin net girdisini hesaplayan bir fonksiyondur. Bazı durumlarda gelen girdilerin değeri dikkate alınırken bazı durumlarda ise gelen girdilerin sayısı önemli olabilmektedir. Bir problem için en uygun toplama fonksiyonu belirlenirken geliştirilmiş bir yöntem yoktur. Genellikle deneme yanılma yoluyla toplama fonksiyonu belirlenmektedir. Bazen her hücrenin toplama fonksiyonunun aynı olması gerekmez. Bu konulara karar vermek tasarımcıya aittir.

Bazı Toplama Fonksiyonları

Toplam	$\text{Net} = \sum_{i=1}^{N} X_i * W_i$
Çarpım	$\text{Net} = \prod_{i=1}^{N} X_i * W_i$
Maksimum	$\text{Net} = \text{Max}(X_i * W_i)$
Minimum	$\text{Net} = \text{Min}(X_i * W_i)$

Toplam Fonksiyonu : Ağırlık değerleri girdiler ile çarpılır ve bulunan değerler birbirleriyle toplanarak Net girdi hesaplanır.

Çarpım Fonksiyonu : Ağırlık değerleri girdiler ile çarpılır ve daha sonra bulunan değerler birbirleriyle çarpılarak Net Girdi Hesaplanır.

Maksimum Fonksiyonu : n adet girdi içinden ağırlıklar girdilerle çarpıldıktan sonra içlerinden en büyüğü Net girdi olarak kabul edilir.

Minimum Fonksiyonu : n adet girdi içinden ağırlıklar girdilerle çarpıldıktan sonra içlerinden en küçüğü Net girdi olarak kabul edilir.

1.3 Yapılan Deneysel Çalışma Ayarları

KNN ve YSA performanslarını değerlendirmek için UCI makine öğrenme deposundan 2 veri seti alınmıştır. Veri setlerinin özellikleri tablo 1'de görülmektedir.

Tablo 2. Veri setlerinin özellikleri

					Etiketlerin Dağılımı	
Veri Seti No	Veri Seti Adı	Toplam Veri Sayısı	Nitelik Sayısı	Etiket Sayısı	Etiket	Sayı
1	Electrical Grid Stability Simulated	6000	13	2	0	3833
					1	2161
2	Avila	3509	10	6	1	1640
					2	105
					3	294
					4	1019
					5	239
					6	212

1 nolu veri setinin 1-2000 arası YSA ve KNN ağırlıklarının bulunmasında, 2001-4000 arası performans değerlendirmesinde ve 4001-6000 arası KNN'de sınıflandırma yapılmak üzere bölünmüştür.

2 nolu veri setinin 1001-2000 arası YSA ve KNN ağırlıklarının bulunmasında, 2001-3509 arası performans değerlendirmesinde ve 1-1000 arası KNN'de sınıflandırma yapılmak üzere bölünmüştür.

KNN ve YSA ağırlıklarının bulunmasında Simbiyotik Organizmalar Arama Algoritması kullanılmıştır. Maksimum iterasyon sayısı (1.000 * problem boyutu) + 80.000 olarak belirlenmiştir. Hazırlanan modeller 4 kez çözümlenmiştir ve en düşük hataya sahip model seçilmiştir.

1.3.4 Avila Veri Seti için Yapılan Deneysel Çalışmalar

Baz Knn algoritması için belirlenen 3 komşu sayısı sayısı ve Öklid uzaklığı için sınıflandırma performansı %63.7'dir. Aynı modelin sezgisel algoritma ile gelişitirilmiş halinde ise başarı oranı %91.1'e çıkartılmıştır. Sınıflandırma performansını daha da iyileştirebilmek için oylama türü ve uzaklık metrikleri sırasıyla ağırlıklı oylama ve manhattan uzaklığı ile değiştirilmiştir. Veri setindeki bağımsız değişkenlerin sınıflandırmadaki etki oranları tablo 3' de verilmiştir. Elde edilen başarı oranı Şekil 2' de verilmiştir.

Tablo:3 Sınıflandırmadaki ağırlık değerleri

Ağırlıklar				
$A_1 = 0.5054$	$A_2 = 0.0740$	$A_3 = 0.0081$	$A_4 = 0.3384$	$A_5 = 0.1306$
$A_6 = 0$	$A_7 = 0$	$A_8 = 0$	$A_9 = 0$	$A_{10} = 0.0083$

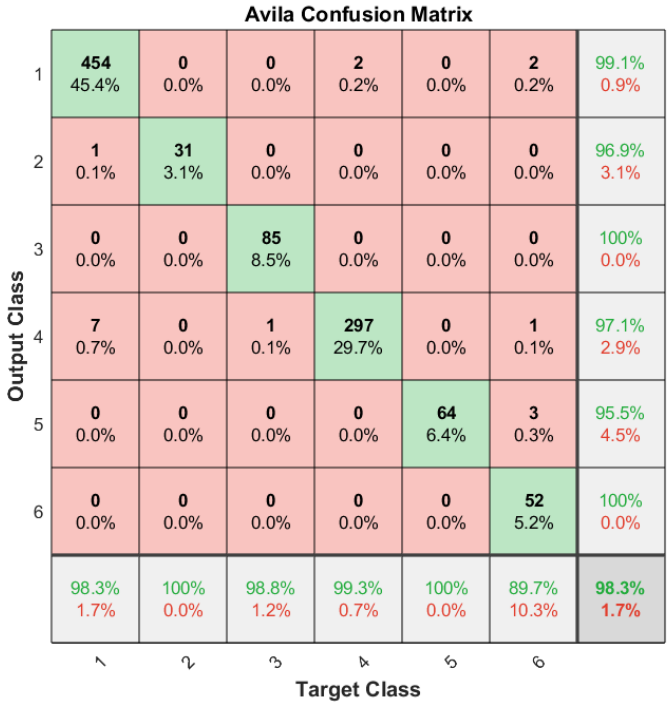

Şekil 2. KNN Modelinin Sınıflandırma Performansı

YSA için ise tek çıkışlı yaklaşımında sırasıyla 1. Ve 2. Gizli katmanları 2-6, 3-3, 3-5 ve 5-4 olacak şekilde 4 farklı model oluşturulmuştur. Ağırlıkların bulunmasında en küçük hatayı veren 2-6'lı model olmuştur. 494 hatalı sınıflandırma yapan ysa modeli tablo 4'de verilmiştir. Şekil 3'te ise doğrulama performansı verilmiştir.

Tablo 4. YSA Modeli

Katmanlar	Nöron	Ağırlıklar			Aktivasyon Fonksiyonları	Birleştirme Fonksiyonları
1. Gizli Katman	1	$A_1 = -1$	$A_2 = 0.7115$	$A_3 = 0.6908$	Relu	Toplam
		$A_4 = -0.0150$	$A_5 = 0.1719$	$A_6 = 0.3562$		
		$A_7 = -0.5071$	$A_8 = -0.5257$	$A_9 = 0.6745$		
		$A_{10} = -0.7367$				
	2	$A_1 = 0.4063$	$A_2 = -0.9420$	$A_3 = -0.3405$	Sigmoid	Çarpım
		$A_4 = 0.2612$	$A_5 = 0.8698$	$A_6 = -0.6731$		
		$A_7 = 1$	$A_8 = 0.9769$	$A_9 = -0.9936$		
		$A_{10} = -0.2967$				
2. Gizli Katman	1	$A_1 = 0.9742$	$A_2 = -0.1817$		Sinüs	Toplam
	2	$A_1 = -0.2625$	$A_2 = -0.9720$		Sinüs	Max
	3	$A_1 = -0.0878$	$A_2 = 0.0763$		Relu	Toplam
	4	$A_1 = 0.9997$	$A_2 = 0.4565$		Sinüs	Max
	5	$A_1 = -0.9978$	$A_2 = -0.1167$		Leaky Relu	Min
	6	$A_1 = 0.5574$	$A_2 = 0.4346$		Leaky Relu	Toplam
Çıkış Katman	1	$A_1 = -0.9481$	$A_2 = 0.4646$	$A_3 = 0.8436$	Sinüs	Max
		$A_4 = 1$	$A_5 = -0.9430$	$A_6 = 0.6355$		

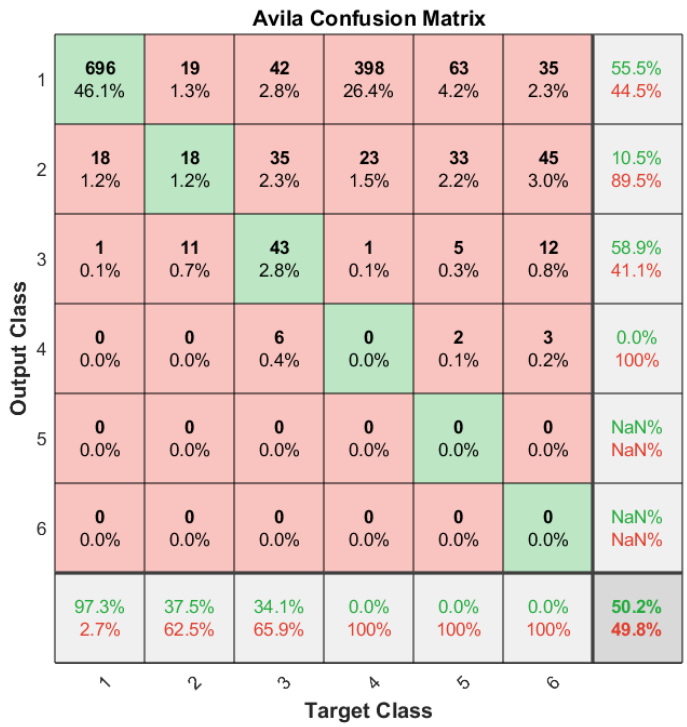

Şekil 3. Tek Çıkışlı 2-6 YSA Modelinin Sınıflandırma Performansı

Tek çıkışlı modeldeki hata oranını düşürmek için, çıkış katmanındaki nöron sayısı 1 yerine, etiket sayısı kadar yapılmıştır. Bu yaklaşımında sırasıyla 1. Ve 2. Gizli katmanları 2-6, 3-3, 3-5 ve 5-4 olacak şekilde 4 farklı model oluşturulmuştur. Ağırlıkların bulunmasında en küçük hatayı veren 3-3'lı model olmuştur. 394 hatalı sınıflandırma yapan ysa modeli tablo 5'de verilmiştir. Şekil 4'te ise doğrulama performansı verilmiştir.

Tablo 5. YSA Modeli

Katmanlar	Nöron	Ağırlıklar			Aktivasyon Fonksiyonları	Birleştirme Fonksiyonları
1. Gizli Katman	1	A_1 = -0.6486	A_2 = -0.6091	A_3 = -0.5010	Hiperbolik Tanjant	Toplam
		A_4 = -0.9592	A_5 = 0.9996	A_6 = -0.9928		
		A_7 = -0.5777	A_8 = 0.2214	A_9 = -0.5626		
		A_{10} = 0.5417				
	2	A_1 = 0.3963	A_2 = 0.8691	A_3 = 0.2525	Sigmoid	Çarpım
		A_4 = 0.5361	A_5 = 0.1367	A_6 = -0.7476		
		A_7 = -0.7828	A_8 = -0.9457	A_9 = -0.8437		
		A_{10} = 0.7480				
	3	A_1 = 0.7983	A_2 = -0.1171	A_3 = -0.4140	Sigmoid	Toplam
		A_4 = -0.2794	A_5 = -0.6979	A_6 = 0.6022		
		A_7 = -0.6254	A_8 = 0.1287	A_9 = -0.3304		
		A_{10} = -0.7812				
2. Gizli Katman	1	A_1 = -0.1895	A_2 = -0.6979	A_3 = 0.9998	Sinüs	Toplam
	2	A_1 = 0.9291	A_2 = 0.1766	A_3 = -0.8691	Relu	Toplam
	3	A_1 = 0.4399	A_2 = 1	A_3 = -0.5450	Sinüs	Toplam
Çıkış Katman	1	A_1 = 0.5857	A_2 = -0.3979	A_3 = -0.7955	Sigmoid	Toplam
	2	A_1 = 0.5107	A_2 = 0.2086	A_3 = -0.7082	Sinüs	Toplam
	3	A_1 = -0.9992	A_2 = 0.4199	A_3 = -0.0927	Sigmoid	Toplam
	4	A_1 = 0.1132	A_2 = 1	A_3 = -0.9956	Sigmoid	Max
	5	A_1 = -0.1682	A_2 = -0.6699	A_3 = 0.4172	Sigmoid	Max
	6	A_1 = -0.7640	A_2 = -0.9883	A_3 = -0.5763	Sinüs	Toplam

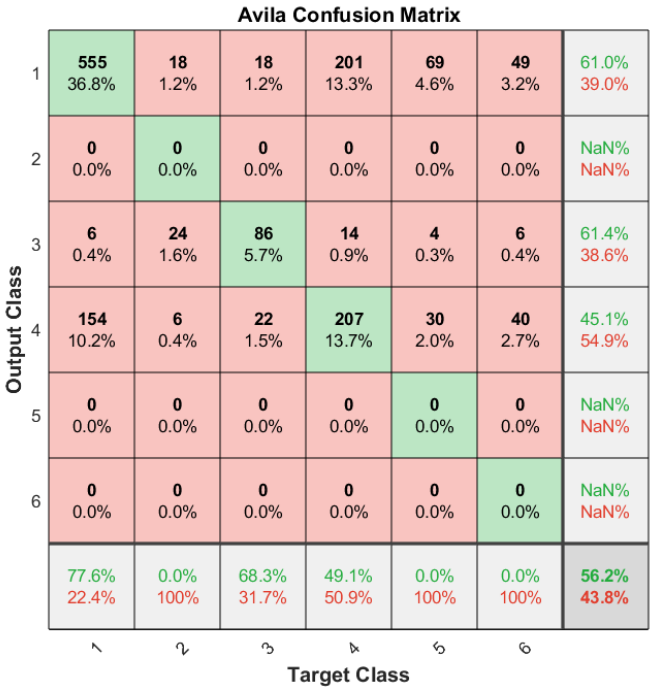

Şekil 4. Multi Çıkışlı 3-3 YSA Modelinin Sınıflandırma Performansı

1.3.5 Electrical Grid Stability Simulated Veri Seti için Yapılan Deneysel Çalışmalar

Baz Knn algoritması için belirlenen 7 komşu sayısı sayısı ve Öklid uzaklığı için sınıflandırma performansı %90.1'dir. Aynı modelin sezgisel algoritma ile gelişitirilmiş halinde ise başarı oranı %99.9'e çıkartılmıştır. Veri setindeki bağımsız değişkenlerin sınıflandırmadaki etki oranları tablo 6 de verilmiştir. Elde edilen başarı oranı Şekil 5'de verilmiştir.

Tablo 6. KNN Modeli

Ağırlıklar				
$A_1 = 0$	$A_2 = 0$	$A_3 = 0$	$A_4 = 0$	$A_5 = 0$
$A_6 = 0$	$A_7 = 0$	$A_8 = 0$	$A_9 = 0$	$A_{10} = 0.0865$

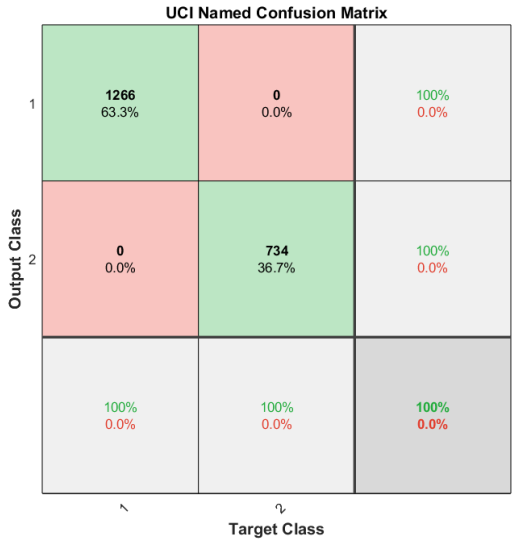

Şekil 5. KNN Modelinin Sınıflandırma Performansı

Bu veri setinde ön çalışma için oluşturulan Ysa modelinde ağırlıkların bulunmasında 100% sınıflandırma başarısı elde edildiğinden dolayı başka modeller oluşturulmamıştır. Oluşturulan model Şekil 6'da verilmiştir.

Tablo 7. YSA Modeli

Katmanlar	Nöron	Ağırlıklar			Aktivasyon Fonksiyonları	Birleştirme Fonksiyonları
1. Gizli Katman	1	A_1 = -0.4743	A_2 = 0.7167	A_3 = 0.7549	Leaky Relu	Min
		A_4 = 0.1788	A_5 = 0.9942	A_6 = -0.1238		
		A_7 = -0.6329	A_8 = 0.9706	A_9 = 0.7560		
		A_{10} = -0.1720	A_{11} = -0.2700	A_{12} = 0.1803		
		A_{13} = -0.0390				
	2	A_1 = 0.9583	A_2 = -0.5886	A_3 = 0.3329	Sinüs	Çarpım
		A_4 = 0.3451	A_5 = 0.1357	A_6 = -0.2106		
		A_7 = 0.9174	A_8 = 0.9851	A_9 = 0.1708		
		A_{10} = 0.1259	A_{11} = -0.5872	A_{12} = 0.4105		
		A_{13} = 0.5817				
	3	A_1 = -0.2376	A_2 = -0.9279	A_3 = -0.1653	Hiperbolik Tanjant	Çarpım
		A_4 = 0.4282	A_5 = 0.5861	A_6 = 0.9561		
		A_7 = 1.0000	A_8 = -0.8052	A_9 = -0.1032		
		A_{10} = 0.0583	A_{11} = 0.4980	A_{12} = -0.5675		
		A_{13} = 0.1785				
	4	A_1 = 0.1232	A_2 = 1.0000	A_3 = 0.0506	Eşik Değer	Min
		A_4 = -0.5537	A_5 = -0.4689	A_6 = 0.1405		
		A_7 = 0.9488	A_8 = -0.7889	A_9 = -0.7788		
		A_{10} = 0.4530	A_{11} = -0.0546	A_{12} = 0.8337		
		A_{13} = 0.3423				
	5	A_1 = -0.1931	A_2 = -0.2716	A_3 = 0.0823	Leaky Relu	Max
		A_4 = 0.0042	A_5 = -0.3358	A_6 = -0.3611		
		A_7 = 0.3664	A_8 = -0.9996	A_9 = -0.8766		
		A_{10} = -0.4157	A_{11} = 0.0213	A_{12} = -0.0135		
		A_{13} = 0.9162				
2. Gizli Katman	1	A_1 = 0.3647	A_2 = 0.6162	A_3 = -0.3919	Sigmoid	Max
		A_4 = -0.0144	A_5 = -0.0481			
	2	A_1 = 0.2387	A_2 = 0.6323	A_3 = -0.9577	Sinüs	Toplam
		A_4 = 0.8067	A_5 = -0.4010			
	3	A_1 = 1.0000	A_2 = 0.6553	A_3 = -0.9990	Sinüs	Çarpım
		A_4 = 0.9814	A_5 = 0.2289			
	4	A_1 = 0.6334	A_2 = -0.2447	A_3 = -0.8235	Sigmoid	Min
		A_4 = 0.4254	A_5 = -0.7692			
Çıkış Katman	1	A_1 = 0.9992	A_2 = 0.5232	A_3 = 0.1789	Esik Değer	Toplam
		A_4 = 0.7741				

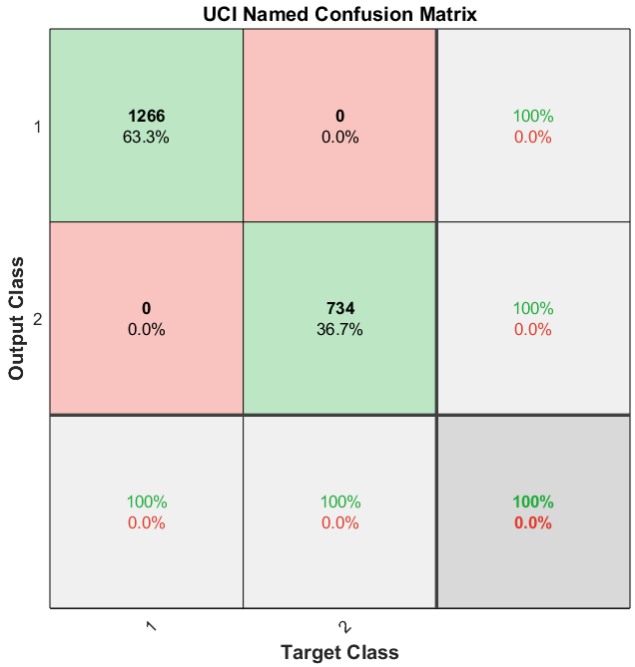

Şekil 6. Tek Çıkışlı 5-4 YSA Modelinin Sınıflandırma Performansı

1.4 Sonuç

Electrical Grid Stability Simulated veri setinde Sezgisel KNN VE Sezgisel YSA genel olarak performans açısından benzer sonuçlar vermiştir. Avila veri setinde ise Sezgisel KNN in sınıflandırma performansı %40.1 lik daha fazla doğruluk üstünlüğü göstermiştir. Veri setlerinin homojenlik durumu göz önüne alındığında Avila veri seti yeterince homojen değildir. Homojen olmayan veri setinde Sezgisel YSA'nın doğruluk oranında büyük ölçüde azalma vardır. Ancak Sezgisel KNN aynı durumlar göz önüne alındığında başarı oranını koruyabilmiştir. Veri setinin homojenlik durumunun Sezgisel YSA'nın sınıflandırma performansı üzerindeki olumsuz etkisi bariz görülmektedir. Fakat Sezgisel KNN de böyle bir etki görülmemiştir. Homojen olmayan veri setlerinin ysa sınıflandırma performansı üzerindeki etkisinin daha iyi araştırılabilmesi için homojen olmayan farklı veri setlerinde deneysel çalışmalar yapılabilir. Sezgisel KNN'de veri setlerindeki bağımsızlık değişkenlerin sınıflandırma etki oranları incelendiğinde etki derecesi çok düşük nitelikler bulunmaktadır. Hata oranında çok büyük bir kötüleşme yapmayacak optimum bir eşik değerin belirlenmesi durumunda bu eşik değerden küçük olan nitelikler çıkartılarak boyut azaltma işlemi yapılır. Bu işlemin ardından çoklu sezgisel Knn algoritmasının sınıflandırma performansı artarken problemin boyutunun küçülmesinden dolayı sınıflandırmadaki işlem adımlarında azalma olur dolayısıyla yapılan işlem hızlandırılmış olur.

1.5 Kaynakça

https://medium.com/@ayyucekizrak/derin-öğrenme-için-aktivasyon-fonksiyonlarının-karşılaştırılması-cee17fd1d9cd

http://bilgisayarkavramlari.sadievrenseker.com/2013/03/31/siniflandirma-classification/

https://medium.com/@k.ulgen90/makine-öğrenimi-bölüm-2-6d6d120a18e1

http://bilgisayarkavramlari.sadievrenseker.com/2008/11/17/knn-k-nearest-neighborhood-en-yakin-k-komsu/

https://archive.ics.uci.edu/ml/datasets/Electrical+Grid+Stability+Simulated+Data+

https://archive.ics.uci.edu/ml/datasets/Avila